

2021 阿里巴巴全球数学竞赛

决赛试题

应用与计算数学赛道

一、考虑如下偏微分方程

$$(1) \quad -\nabla \cdot (a \nabla u(x)) = f(x), \quad \text{in } \mathbb{R}^3,$$

其中 a 是一个正定 3×3 常矩阵, 而 $f \in C_0^\infty(B_1)$ 是个光滑紧支函数, 仅在 $\mathbb{R}^3$ 中的单位球 B_1 内非零。

- 请问 f 满足什么条件时, 方程 (1) 有解?
- 方程 (1) 的解是否唯一? 如果唯一, 请证明; 如果不唯一, 请举出反例, 并且说明如何提更多的条件使得解唯一。
- 假设已知方程的解 $u(x)$ 满足

$$|u(x)| = O(|x|^{-3}) \quad \text{as } |x| \rightarrow \infty.$$

请问这说明右端项 f 满足什么条件? 更进一步的, 请给出及验证当 $|x| \rightarrow \infty$ 时, 方程解 u 的 (任意高阶) 渐进展开式。

二、我们用如下的随机过程来帮助理解神经网络的训练动态。考虑一个二分类的数据集, 每类有 n 个数据点。令实数轴上的随机过程 $\{X^i(m) : m = 0, 1, \dots\}$ 表示第一类的第 i 个数据点, 这里 m 表示迭代次数。同理, $\{Y^j(m) : m = 0, 1, \dots\}$ 表示第二类的数据点。

假设 $X^1(0), \dots, X^n(0)$ 独立同分布, $Y^1(0), \dots, Y^n(0)$ 同样是独立同分布并且分布与 X 相同。在第 $m \geq 1$ 次迭代, 从 $2n$ 个训练数据点中随机均匀选一个点。假设神经网络迭代过程中梯度的影响取决于更新点属于哪个类: 如果选中的点是第一类中的第 I_m 个点, 那么这次迭代满足

$$X^i(m) = X^i(m-1) + \frac{\alpha}{M} X^{I_m}(m-1) + \zeta_{m-1}^i$$

$$Y^j(m) = Y^j(m-1) + \frac{\beta}{M} X^{I_m}(m-1) + \zeta_{m-1}^j$$

对所有 $1 \leq i, j \leq n$ (注意 I_m 是 $\{1, \dots, n\}$ 上的均匀分布)。如果选中的是第二类中的第 J_m 个点 (J_m 也是 $\{1, \dots, n\}$ 上的均匀分布), 那么

$$X^i(m) = X^i(m-1) + \frac{\beta}{M} Y^{J_m}(m-1) + \zeta_{m-1}^i$$

$$Y^j(m) = Y^j(m-1) + \frac{\alpha}{M} Y^{J_m}(m-1) + \zeta_{m-1}^j.$$

这里 $\zeta_{m-1}^i, \zeta_{m-1}^j$ 是 iid 均值为 0 方差为 σ^2/M 的噪音, 正数 α, β 分别表示迭代对于同类还是异类的强度。

- 令 $M \rightarrow \infty$, 简要解释 (不需要严格) 为什么 $X^i(m)$ 和 $Y^j(m)$ 会收敛到满足如下方程的连续时间随机过程 $X^i(t)$ 和 $Y^j(t)$ ($t = m/M$):

$$(2) \quad \begin{aligned} dX^i(t) &= \left(\frac{\alpha}{2} \bar{X}(t) + \frac{\beta}{2} \bar{Y}(t) \right) dt + \sigma dB^i(t) \\ dY^j(t) &= \left(\frac{\alpha}{2} \bar{Y}(t) + \frac{\beta}{2} \bar{X}(t) \right) dt + \sigma dW^j(t). \end{aligned}$$

这里 $t \geq 0$, $\bar{X}(t) := (X^1(t) + \dots + X^n(t))/n$, $\bar{Y}(t) := (Y^1(t) + \dots + Y^n(t))/n$, 以及 B^i, W^j ($1 \leq i, j \leq n$) 是独立的标准布朗运动。

- 写出 $\bar{X}(t)$ 和 $\bar{Y}(t)$ 在极限 $n \rightarrow \infty$ 下满足的两个常微分方程。

应用与计算数学赛道

- c) 给定边界条件 $\mathbb{E} X^i(0) = c_x$ 和 $\mathbb{E} Y^j(0) = c_y$, 解常微分方程。
- d) 回到有限 n 的情形。将随机微分方程(2)中的 $\bar{X}, \bar{Y}$ 换成 (c) 的 (非随机) 解。(因此你可以假设(2)中 $2n$ 个方程是相互独立的。) 假设 $c_x \neq c_y$, 证明当且仅当 $\alpha > \beta$ 时, 这 $2n$ 个点可分的概率随着 $t \rightarrow \infty$ 趋向于 1。这里可分的意思是要么 $\min_i X^i(t) > \max_j Y^j(t)$ 或者 $\max_i X^i(t) < \min_j Y^j(t)$ 。(联系深度学习, 这个结果意味着训练误差趋向于 0 当且仅当迭代对相同类的点的影响大于对不同类型的点。这个就是神经网络的局域弹性现象。)
- e) 考虑 $\alpha > \beta$ 。假设 $c_x \neq c_y$ 以及 $X^i(0), Y^j(0)$ 是概率 1 有界的随机变量。对于很大的 n , 什么时候这 $2n$ 个数据点第一次可分? 你只需要对这个 (随机) 时间给出一个估计。(只需要给出关于 n 的阶, 比如 $O(\sqrt{n}), O(\log n)$ 。)

三、考虑一个线性的 Fokker-Planck 方程

$$(3) \quad \partial_t f = \Delta f + \nabla \cdot [f \nabla V(x)], \quad t > 0, x \in \Omega \subset \mathbb{R}^d.$$

这里 $f = f(t, x) \geq 0$ 是一个依赖于时间 t 和位置 x 的概率密度函数, $V(x)$ 是一个给定的函数在区域 Ω 里有下界。注意到 Fokker-Planck 方程 (3) 可以视为一个输运扩散方程。为数值求解 (3), 我们引进函数 $M(x) = \exp(-V(x))$, 把它写成一个等价形式

$$(4) \quad \partial_t f = \nabla \cdot \left(M \nabla \left(\frac{f}{M} \right) \right).$$

这样的话, 这个方程可以看成是一个变系数的扩散方程, 然后自然地用有限差分法来离散求解。具体来说, 我们假定 $d = 1, \Omega = [a, b]$, 然后把 $[a, b]$ 等分成 N 个长度是 $\Delta x = (b - a)/N$ 的小区间, 区间中点是 $x_i = a + (i - 1/2)\Delta x, i = 1, \dots, N$, 区间端点是 $x_{i+1/2} = a + i\Delta x, i = 0, \dots, N$ 。对方程 (4) 在空间上使用中心差分, 时间上使用向前 Euler 法就得到格式

$$(5) \quad \frac{f_i^{n+1} - f_i^n}{\Delta t} = \frac{F_{i+1/2}^n - F_{i-1/2}^n}{\Delta x}, \quad F_{i+1/2}^n := \frac{1}{\Delta x} M_{i+1/2} \left(\frac{f_{i+1}^n}{M_{i+1}} - \frac{f_i^n}{M_i} \right),$$

这里 f_i^n 是 f 在 x_i 处和时间 $t_n = n\Delta t$ 时对 f 的数值逼近, M_i 和 $M_{i+1/2}$ 是 M 分别在 x_i 和 $x_{i+1/2}$ 处的取值。在边界 a 和 b 处我们取 $F_{1/2}^n = F_{N+1/2}^n = 0$ 。

- a) 对于数值格式 (5), 证明能量泛函 $E(f) := \int_{\Omega} f \ln \left(\frac{f}{M} \right) dx$ 在离散意义下是单调下降的, 即, 证明

$$E_{\Delta}(f_i^{n+1}) \leq E_{\Delta}(f_i^n), \quad \text{这里 } E_{\Delta}(f_i^n) := \sum_{i=1}^N f_i^n \ln \left(\frac{f_i^n}{M_i} \right).$$

陈述清楚需要的条件。这个数值解会最终收敛到一个稳态解吗? 是的话, 写出稳态解的形式; 不是的话, 说明原因。

- b) 我们还可以使用向后 Euler 法离散上面的方程, 得到格式

$$\frac{f_i^{n+1} - f_i^n}{\Delta t} = \frac{F_{i+1/2}^{n+1} - F_{i-1/2}^{n+1}}{\Delta x}.$$

对这个格式, 重复 a) 里的所有问题。

应用与计算数学赛道

四、设 $B \in \mathbb{R}^{m \times m}$ 为对称半正定矩阵，且其秩 $\text{rank}(B) = r > 0$ 。设 $X \in \mathbb{R}^{m \times k} (m \geq k)$ 满足 $X^\top X = I_k$ 。设 BX 有奇异值分解 $BX = UDV^\top$ ，这里 $U \in \mathbb{R}^{m \times k}$ 及 $V \in \mathbb{R}^{k \times k}$ 是正交矩阵满足 $U^\top U = V^\top V = I_k$ ， $D = \text{diag}(D_{11}, \dots, D_{kk})$ 是对角矩阵，对角元 $D_{ii} \geq 0, i = 1, 2, \dots, k$ 是 BX 的奇异值。请证明

$$\text{tr}(U^\top BU) - \text{tr}(X^\top BX) \geq \frac{\lambda_r(B)}{\|B\|_2^2} \|(I - XX^\top)BX\|_F^2.$$

这里 $\text{tr}(\cdot)$ 代表方阵的迹：

$$\text{tr}(A) := \sum_{i=1}^t A_{ii}, \forall A = (A_{ij}) \in \mathbb{R}^{t \times t}, t \in \mathbb{N}$$

$\|\cdot\|_F$ 代表矩阵的 Frobenius 范数：

$$\|A\|_F := \sqrt{\sum_{i,j=1}^t A_{ij}^2}, \forall A = (A_{ij}) \in \mathbb{R}^{t \times t}, t \in \mathbb{N}.$$

五、张师傅最近正在研究算法用于调节各种产品的参数。这样的参数一般可以通过极小化 $\mathbb{R}^n$ 上的某个损失函数 f 求得。预赛中，我们提到张师傅的一个项目。在此项目中，损失函数是另外一个课题组提供的，且该课题组不能向张师傅给出此函数的内部细节，而只提供一个接口用于计算任意 $\mathbf{x} \in \mathbb{R}^n$ 处的函数值 $f(\mathbf{x})$ 。所以，张师傅必须仅基于函数值来极小化 f 。好在该问题的维度 n 不是很高 (10 左右)。另外，提供函数的同事还告知张师傅不妨先假设 f 是光滑的。

为解决该问题，张师傅提出了“自动前后调整算法” (Automated Forward/Backward Tuning, AFBT，算法 1)。在第 k 次迭代中，AFBT 通过前后调整 $\mathbf{x}_k$ 的单个分量得到 $2n$ 个点 $\{\mathbf{x}_k \pm t_k \mathbf{e}^i : i = 1, \dots, n\}$ ，其中 t_k 为步长；然后，令 $\mathbf{y}_k$ 为这些点中函数值最小的一个，并检查 $\mathbf{y}_k$ 是否使 f 充分减小；若是，取 $\mathbf{x}_{k+1} = \mathbf{y}_k$ ，并将步长增倍；否则，令 $\mathbf{x}_{k+1} = \mathbf{x}_k$ 并将步长减半。在算法 1 中， $\mathbf{e}^i$ 表示 $\mathbb{R}^n$ 中的第 i 个坐标向量，它的第 i 个分量为 1，其余皆为 0； $\mathbf{1}(\cdot)$ 为指示函数——若 $f(\mathbf{x}_k) - f(\mathbf{y}_k)$ 至少为 t_k^2 之平方，则 $\mathbf{1}[f(\mathbf{x}_k) - f(\mathbf{y}_k) \geq t_k^2]$ 取值为 1，否则为 0。

算法 1 自动前后调整算法 (AFBT)

输入 $\mathbf{x}_0 \in \mathbb{R}^n, t_0 > 0$. 对 $k = 0, 1, 2, \dots$, 执行以下循环.

- 1: $\mathbf{y}_k := \text{argmin} \{f(\mathbf{y}) : \mathbf{y} = \mathbf{x}_k \pm t_k \mathbf{e}^i, i = 1, \dots, n\}$ # 计算损失函数.
- 2: $s_k := \mathbf{1}[f(\mathbf{x}_k) - f(\mathbf{y}_k) \geq t_k^2]$ # 是否充分下降? 是: $s_k = 1$; 否: $s_k = 0$.
- 3: $\mathbf{x}_{k+1} := (1 - s_k)\mathbf{x}_k + s_k\mathbf{y}_k$ # 更新迭代点.
- 4: $t_{k+1} := 2^{2s_k-1}t_k$ # 更新步长. $s_k = 1$: 步长增倍; $s_k = 0$: 步长减半.

AFBT 运作良好，且在预赛中我们证明了该算法在一定条件下收敛。不过，张师傅最近收到一个情况类似但变量更多的问题 (n 约为 50)，AFBT 求解该问题效率不佳。AFBT 的每次迭代都计算 $2n$ 次函数值，消耗大量计算资源，很不环保。张师傅需要改进 AFBT 以提高计算效率。

现在我们对损失函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 作出如下假设。

假设 1. f 为凸函数，即对任何 $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$ 与 $\alpha \in [0, 1]$ 都有

$$f((1 - \alpha)\mathbf{x} + \alpha\mathbf{y}) \leq (1 - \alpha)f(\mathbf{x}) + \alpha f(\mathbf{y}).$$

假设 2. f 在 $\mathbb{R}^n$ 上可微且 ∇f 在 $\mathbb{R}^n$ 上 L -Lipschitz 连续。

假设 3. f 的水平集有界，即对任意 $\lambda \in \mathbb{R}$ ，集合 $\{\mathbf{x} \in \mathbb{R}^n : f(\mathbf{x}) \leq \lambda\}$ 皆有界。

在假设 1 与假设 2 下，可以证明

$$\langle \nabla f(\mathbf{x}), \mathbf{y} - \mathbf{x} \rangle \leq f(\mathbf{y}) - f(\mathbf{x}) \leq \langle \nabla f(\mathbf{x}), \mathbf{y} - \mathbf{x} \rangle + \frac{L}{2} \|\mathbf{x} - \mathbf{y}\|^2$$

应用与计算数学赛道

对任何 $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$ 成立；假设 1 与假设 3 则保证 f 在 $\mathbb{R}^n$ 上取到有限的最小值 f^* 。

a) 为降低每一步迭代的计算代价，张师傅提出了“随机前后调整算法”（Randomized Forward/Backward Tuning, RFBT, 算法 2）。RFBT 只在循环的第 1 行与 AFBT 不同；每步迭代，该算法仅随机选择 $\mathbf{x}$ 的一个分量进行调整。但是张师傅发现 RFBT 似乎并不理想：在满足前述假设的测试问题上，他经常观察到 RFBT 产生的 $\{f(\mathbf{x}_k)\}$ 始终不靠近 f^* 。试给出一个具体的例子，使得假设 1-3 成立，但对于 RFBT 有

$$\Pr \left(\lim_{k \rightarrow \infty} f(\mathbf{x}_k) = f^* \right) < 1.$$

请给出损失函数 f 的表达式，指明初始点 $\mathbf{x}_0$ 与初始步长 t_0 如何选取，并详述上式中概率的估计。

算法 2 随机前后调整算法 (RFBT)

将 AFBT 第 1 行改为 $\mathbf{y}_k := \operatorname{argmin} \{f(\mathbf{y}) : \mathbf{y} = \mathbf{x}_k \pm t_k \mathbf{e}^{i_k}\}$ ，其中 i_k 从 $\{1, \dots, n\}$ 的均匀分布中随机抽取，且与 $\{i_0, \dots, i_{k-1}\}$ 独立。其余各行与 AFBT 完全相同。

b) 仔细研究 RFBT 后，张师傅意识到 $\mathbf{x}$ 的各分量不一定要分开逐个调整。因此，他修改 RFBT，得到了“球面前后调整算法”（Spherical Forward/Backward Tuning, SFBT, 算法 3）。SFBT 只在循环的第 1 行与 AFBT 不同；每步迭代，该算法沿一个随机方向调整 $\mathbf{x}$ 。张师傅发现 SFBT 效果良好，可以处理更大的问题。对于 SFBT，证明

$$\Pr \left(\lim_{k \rightarrow \infty} f(\mathbf{x}_k) = f^* \right) = 1.$$

算法 3 球面前后调整算法 (SFBT)

将 AFBT 第 1 行改为 $\mathbf{y}_k := \operatorname{argmin} \{f(\mathbf{y}) : \mathbf{y} = \mathbf{x}_k \pm t_k \mathbf{v}_k\}$ ，其中 $\mathbf{v}_k$ 从 $\mathbb{R}^n$ 中单位球面上的均匀分布中随机抽取，且与 $\{\mathbf{v}_0, \dots, \mathbf{v}_{k-1}\}$ 独立。其余各行与 AFBT 完全相同。